

1. Tiempos de Respuesta

Un startup de streaming está comparando la latencia (en milisegundos) de dos proveedores de nube: Cloud A y Cloud B. Tienen una muestra de $n = 5,000$ peticiones para cada uno.

* Reporte del Analista: Debido a que la prueba de Levene (Stat= 145,2, $p = 0,000$) confirmó que las varianzas no son iguales, procedimos con un test t de Welch. El resultado ($t = 0,05$, $p = 0,293$) indica que no hay una diferencia importante entre los grupos; básicamente, las medias se comportan de la misma manera.

a) Sabiendo que los tiempos de respuesta suelen seguir distribuciones fuertemente asimétricas a la derecha, ¿por qué confiar exclusivamente en la Prueba t de Welch es un error grave para el negocio, incluso si corrige la heterocedasticidad?

Respuesta: Confiar en la Prueba t de Welch en este escenario es un error conceptual crítico porque esta prueba tiene un supuesto matemático estricto: asume que la variable analizada sigue una distribución normal en ambos grupos.

Aunque es cierto que la Prueba t de Welch relaja el supuesto de homocedasticidad (es decir, permite que las varianzas o la dispersión de los datos sean desiguales entre los grupos) mediante la aproximación de Welch-Satterthwaite, sigue siendo una prueba que compara exclusivamente las medias poblacionales.

Cuando los datos presentan una asimetría fuerte hacia la derecha (como suele ocurrir con los tiempos de latencia en la nube), significa que existen valores atípicamente altos que "arrastran" el promedio aritmético, distorsionándolo. Al comparar medias en distribuciones asimétricas, el analista está evaluando un centro matemático que no representa la experiencia real de la mayoría de los usuarios. Las buenas prácticas indican que si la distribución no es normal (lo cual se confirmaría previamente con una prueba de Shapiro-Wilk), el enfoque paramétrico debe descartarse.

b) Si el proveedor B tiene una mediana mucho más baja, pero experimenta picos de latencia extremos (anomalías), ¿qué prueba no paramétrica debió ejecutar el analista para capturar qué proveedor es consistentemente más rápido? Justifica la matemática detrás de tu elección.

Respuesta: El analista debió utilizar la Prueba U de Mann-Whitney.

Justificación matemática: La Prueba U de Mann-Whitney es la alternativa directa a la prueba t cuando los datos no cumplen con el supuesto de normalidad. Su idoneidad para este caso de negocio radica en cómo procesa la información matemáticamente:

1. **Transformación a Rangos:** En lugar de calcular y comparar medias matemáticas (que se verían severamente afectadas por los picos de latencia extremos del Proveedor B), esta prueba combina todos los datos de ambos proveedores, los ordena de menor a mayor y les asigna una posición o "rango numérico".
2. **Evaluación de Dominancia (Estadístico U):** Una vez jerarquizados, la prueba utiliza el estadístico U para evaluar si los rangos más altos tienden a concentrarse de manera desproporcionada en un grupo específico.
3. **Robustez ante Anomalías:** La hipótesis alternativa de esta prueba postula que un grupo tiende a tener valores estocásticamente (aleatoriamente) mayores que el otro. Al trabajar con posiciones jerárquicas y no con los valores brutos en milisegundos, un pico de latencia extremo de 10,000 ms simplemente recibe el "rango 1", teniendo el mismo peso analítico que una latencia de 500 ms si esta fuera el "rango 2". Esto prescinde totalmente de la distribución normal empírica y permite capturar con precisión qué proveedor es consistentemente más rápido de forma estructural, aislando el ruido generado por las anomalías.

La Justificación Matemática: El poder de la Sumatoria de Rangos (R)

El secreto de por qué esta fórmula ignora los picos extremos de latencia del Proveedor B no está en las multiplicaciones iniciales, sino en cómo se calcula R antes de meterlo a la fórmula.

La Prueba t de Welch (la que usó el analista equivocadamente) utiliza la media matemática, cuya fórmula es $\frac{\sum x_i}{n}$. En la media, se suman los valores brutos en milisegundos. Si el Proveedor B tiene una latencia anómala de 50,000 ms, ese número completo entra a la suma y destruye el cálculo.

La Prueba U de Mann-Whitney, en cambio, construye la suma R a través de un proceso de **transformación ordinal**. Funciona así:

1. **Combinación:** Junta las 5,000 peticiones de Cloud A y las 5,000 de Cloud B en un solo grupo de 10,000 datos.
2. **Ordenamiento:** Ordena esos 10,000 tiempos de respuesta del más rápido al más lento.
3. **Jerarquización (Asignación de Rangos):** Al dato más rápido le asigna el rango numérico 1. Al segundo más rápido el 2. Y así sucesivamente hasta llegar al dato más lento, que recibe el rango 10,000.
4. **Suma (R):** Suma todos los rangos que pertenecen a Cloud A para obtener R_A , y todos los de Cloud B para obtener R_B .

$$U_A = n_A \cdot n_B + \frac{n_A(n_A + 1)}{2} - R_A$$

$$U_B = n_A \cdot n_B + \frac{n_B(n_B + 1)}{2} - R_B$$

Desglosando los Términos Matemáticos:

- n_A y n_B : Son los tamaños de las muestras. En este caso de negocio, sabemos que $n_A = 5000$ y $n_B = 5000$.
- La constante $\frac{n(n+1)}{2}$: Representa la suma máxima teórica de posiciones si un grupo tuviera todos los valores más bajos.
- R_A y R_B (**La clave del éxito**): Representan la **Suma de los Rangos** para el grupo A y el grupo B, respectivamente.

En síntesis:

- Se asignan rangos -> Anomalías (latencias muy altas) asignadas a rangos mayores (#10,000 de 10,000 muestras)
- Se agrupan por grupo (A o B)
- Se determina cuál grupo tuvo rangos (valores en "posiciones") más arriba (en posiciones menos lejanas del 10,000) consistentemente
- Se determina cuál grupo tiene menor rango que el otro (es el que tendrá latencias menores consistentemente)
- Fórmula prueba U
- Menor U corresponde al grupo con latencias consistentemente menores

2. Detección de Fraude

Se evalúa si el Tipo de Tarjeta (Clásica, Oro, Platino) está relacionado con el Tipo de Fraude (Clonación, Phishing, Robo físico). El sistema arroja:

```
> Statistics Results:
Chi-Square: 8.45
DF:         4
P-Value:    0.076
Status:     Non-significant (p > 0.05)
```

a) A nivel puramente estadístico, ¿por qué la frase "aceptamos la Hipótesis Nula" es un error conceptual crítico? ¿Cuál es la forma correcta de redactar este hallazgo?

Respuesta: Decir que "aceptamos la Hipótesis Nula" es un gran error porque va en contra de la regla número uno de la estadística, es decir, nunca damos nada por comprobado al 100%, simplemente decimos si tenemos suficientes datos para afirmar algo nuevo o no.

El objetivo de una prueba de hipótesis nunca es "probar" que la Hipótesis Nula es verdadera, sino únicamente evaluar si los datos de la muestra aportan suficiente evidencia para rechazarla.

Además, es vital entender que el valor p (que aquí es de 0.076) no es la probabilidad de que la Hipótesis Nula sea verdadera. En realidad, es la probabilidad de observar datos tan extremos como los que obtuvimos asumiendo que el estado "por defecto" fuera cierto. Como nuestro $p=0.076$ es mayor que el nivel de significancia convencional del 5% (0.05), simplemente no tenemos pruebas suficientes para declarar que existe un efecto. No encontrar evidencia de un crimen (relación entre tarjeta y fraude) no es una prueba matemática de que el crimen sea imposible; solo significa que tu muestra actual no pudo demostrarlo.

- **La forma correcta de redactar el hallazgo:** "No se rechaza la hipótesis nula". A nivel de negocio, se debería redactar así: "Con un nivel de confianza del 95%, no existe evidencia estadística significativa ($p = 0.076$) para afirmar que el Tipo de Tarjeta está relacionado con el Tipo de Fraude. Por lo tanto, no se rechaza la independencia entre ambas variables."

b) Si la matriz de contingencia muestra que los fraudes en tarjetas "Platino" por "Robo físico" tienen una frecuencia esperada (E_{ij}) de 2.1 eventos, ¿cómo invalida esto matemáticamente el estadístico χ^2 obtenido y qué alternativa analítica o agrupación de datos propondrías?

Respuesta: Este hallazgo invalida por completo el resultado que arrojó el sistema debido a la violación de un supuesto matemático crítico de la prueba Chi-Cuadrada.

La teoría establece que uno de los supuestos más importantes de esta prueba es que ninguna celda de la tabla de contingencia debe tener una "frecuencia esperada" menor a 5. (La frecuencia esperada es la cantidad teórica de eventos que deberíamos ver en esa intersección asumiendo que las variables fueran totalmente independientes). El problema nos indica que la frecuencia esperada (E_{ij}) es de 2.1, lo cual rompe esta regla.

¿Cómo lo invalida matemáticamente?

Para entender el colapso matemático, debemos mirar la fórmula del estadístico Chi-Cuadrado:

$$\chi^2 = \sum_i \sum_j \frac{(O_{ij} - E_{ij})^2}{E_{ij}}$$

En esta sumatoria, el valor de la frecuencia esperada (E_{ij}) está en el **denominador**. Si un denominador es un número muy pequeño (como 2.1), cualquier ligera diferencia en el numerador (es decir, cualquier pequeña desviación entre lo que se observó en la realidad y lo que se esperaba) se amplificará drásticamente al realizar la división. Esto provoca que esa celda en particular infle artificial y desproporcionadamente el valor final de χ^2 . El resultado se vuelve inestable y el valor p calculado pierde su validez matemática, pudiendo generar conclusiones erróneas.

Alternativas analíticas propuestas:

1. **Solución No Paramétrica (La más directa):** La documentación técnica indica explícitamente que, si no se cumple la regla de las frecuencias esperadas mayores a 5, se debe **utilizar la Prueba Exacta de Fisher en lugar de Chi-Cuadrada**.
2. **Agrupación de Datos (Solución de Ingeniería de Características):** Si el negocio requiere mantener la prueba Chi-Cuadrada, la solución es colapsar o fusionar categorías. Por ejemplo, podríamos agrupar las tarjetas "Oro" y "Platino" en una nueva categoría llamada "Tarjetas Premium". Al consolidar categorías con pocos eventos, la "frecuencia esperada" de las nuevas celdas combinadas aumentará, superando el umbral mínimo de 5 eventos y estabilizando el denominador en la fórmula.

3. Selección de Distribuciones

Asigna la distribución de probabilidad (Normal, Binomial, Poisson, Exponencial, Lognormal o Gamma) que mejor modele cada variable y justifica numéricamente tu respuesta:

a) El **número de transacciones fraudulentas detectadas en un sistema de pagos por cada hora operativa**.

- **Distribución:** Poisson.
- **Justificación:** La distribución de Poisson está diseñada matemáticamente para modelar la frecuencia o el **conteo de eventos discretos** que ocurren dentro de un **intervalo continuo y fijo** (en este caso, la ventana de tiempo de "una hora operativa").

A nivel numérico y estructural, se elige Poisson por tres razones:

1. Los resultados son números enteros no negativos (0,1,2,3... fraudes). No puedes tener 1.5 fraudes.
2. No hay un límite superior natural conocido (teóricamente podrían ocurrir infinitos fraudes en una hora, a diferencia de tener un tamaño de muestra fijo).
3. Su único parámetro estadístico es λ (lambda), que representa la tasa promedio de ocurrencia. Si el sistema detecta un promedio de $\lambda = 4$ fraudes por hora, la distribución de Poisson nos permite calcular la probabilidad exacta de observar, por ejemplo, un pico repentino de 10 fraudes en la siguiente hora.

b) El **ingreso mensual en dólares de los usuarios de una plataforma de e-commerce (la mayoría gasta poco, pero unos pocos gastan miles :. sesgo a la derecha)**.

- **Distribución:** Lognormal.
- **Justificación:** La distribución Lognormal es el estándar de oro para modelar variables financieras o de ingresos. El enunciado nos da la pista clave: "la mayoría gasta poco, pero unos pocos gastan miles". Esto describe una dispersión de datos con una **fuerte asimetría positiva** (una "cola" muy larga estirada hacia la derecha). Matemáticamente, utilizar una distribución Normal clásica aquí sería un error grave porque la Normal es simétrica y teóricamente se extiende hacia números negativos; en el comercio electrónico, un usuario no puede tener un "gasto mensual negativo" (el límite absoluto es \$0). La distribución Lognormal soluciona esto porque está estrictamente acotada en cero en su límite inferior, pero crece hacia el infinito positivo, acomodando perfectamente a esos pocos usuarios "ballena" (outliers con gastos extremos) sin distorsionar el modelo central de los usuarios comunes.

c) El tiempo exacto en milisegundos que transcurre hasta que un servidor cloud presenta su primera caída.

- **Distribución:** Exponencial.
- **Justificación:** La distribución Exponencial es la "hermana matemática" de la distribución de Poisson. Mientras que Poisson cuenta cuántos eventos ocurren en un tiempo determinado, la Exponencial modela cuánto tiempo continuo debe transcurrir entre un evento y el siguiente. En este caso, estamos midiendo una variable continua (el "tiempo exacto en milisegundos"). La característica numérica fundamental que obliga a usar esta distribución es la propiedad de **pérdida de memoria** (o propiedad Markoviana). Esta propiedad dicta que la probabilidad de que el servidor falle en el siguiente milisegundo es constante y no depende de cuánto tiempo haya estado funcionando sin fallar previamente. Es el modelo estándar para análisis de supervivencia y tiempos de espera.

d) La cantidad de píxeles defectuosos en un sensor óptico al inspeccionar una muestra de 500 unidades.

- **Distribución:** Binomial.
- **Justificación:** La distribución Binomial es la herramienta matemática precisa cuando estamos contando el número de "éxitos" (que en jerga estadística de calidad significa "encontrar el defecto") dentro de una cantidad fija y predeterminada de intentos. A nivel numérico, sabemos que es Binomial y no Poisson por la restricción de la muestra: tenemos exactamente $n = 500$ unidades. Cada píxel inspeccionado representa un "Ensayo de Bernoulli", un experimento independiente que solo tiene dos resultados binarios posibles: o está defectuoso, o no lo está. Al sumar esos resultados binarios a través de los 500 intentos, la distribución Binomial nos permite calcular probabilidades acotadas (es matemáticamente imposible encontrar 501 defectos en una muestra de 500, un límite duro que Poisson no posee). Su forma está gobernada por dos parámetros: n (el tamaño de la muestra, 500) y p (la probabilidad histórica de que un píxel salga defectuoso).

4. Elección de Correlación

Analizando "Horas de uso" vs. "Satisfacción (1-5 estrellas)", notas una relación monótona pero no lineal, con miles de empates en la calificación "4".

a) Analizando "Horas de uso" vs. "Satisfacción (1-5 estrellas)", notas una relación monótona pero no lineal, con miles de empates en la calificación "4". ¿Por qué el coeficiente de Pearson (r) sería un error técnico en este caso? (Menciona al menos dos supuestos violados).

Respuesta: Utilizar el coeficiente de correlación de Pearson (r) en este escenario es un error técnico grave porque se están violando de manera frontal dos de sus supuestos paramétricos fundamentales:

1. **Supuesto de Linealidad:** El coeficiente de Pearson está diseñado **exclusivamente** para medir el grado de asociación **lineal** entre dos variables. El problema indica explícitamente que la relación es "monótona pero no lineal". Una relación monótona significa que cuando una variable aumenta, la otra también lo hace (o disminuye), pero no necesariamente a un ritmo constante o formando una línea recta (por ejemplo, una curva logarítmica o exponencial). Si aplicamos Pearson a una curva monótona fuerte, el coeficiente subestimaría severamente la relación, arrojando un valor cercano a 0 y haciéndonos concluir erróneamente que las variables no están relacionadas.
2. **Supuesto de Nivel de Medición (Variables Continuas):** Pearson exige que ambas variables sean continuas (de intervalo o razón). Las "Horas de uso" cumplen este requisito, pero la "Satisfacción (1-5 estrellas)" es una **variable ordinal discreta**. En una escala ordinal, sabemos que 5 estrellas es mejor que 4, pero no podemos garantizar matemáticamente que la "distancia" de satisfacción entre 1 y 2 estrellas sea exactamente la misma que entre 4 y 5 estrellas. Aplicar aritmética continua (como medias y varianzas, que componen la fórmula de Pearson) a categorías discretas rompe la validez matemática del estadístico.

b) Entre Spearman (ρ) y Kendall (τ), ¿cuál elegirías para tu análisis exploratorio de datos (EDA) y por qué?

Respuesta: Elegiría el coeficiente de **Kendall** (τ), específicamente su variante **Tau-b** o **Tau-c**.

Justificación matemática: Ambas pruebas (Spearman y Kendall) son alternativas no paramétricas excelentes para evaluar relaciones monótonas y manejar variables ordinales, ya que ambas abandonan los valores brutos y trabajan transformando los datos a rangos (posiciones jerárquicas). Sin embargo, el factor decisivo aquí es la presencia de "miles de empates en la calificación '4'".

1. **El problema de Spearman con los empates:** El coeficiente de correlación de Spearman (ρ) es, matemáticamente hablando, el mismo coeficiente de Pearson, pero aplicado sobre los rangos de los datos en lugar de sus valores originales. Cuando hay empates (múltiples usuarios que dieron "4 estrellas"), Spearman resuelve el conflicto asignando a todos esos valores el *rango promedio*. Cuando tienes "miles de empates", esta promediación masiva de rangos infla artificialmente la varianza y distorsiona el cálculo del coeficiente, volviéndolo inestable e impreciso, incluso si se aplica el "factor de corrección de empates".
2. **La robustez de Kendall:** La Tau de Kendall (τ) utiliza una lógica computacional completamente distinta. No calcula medias ni varianzas de rangos. En su lugar, evalúa combinatoria pura comparando **pares de observaciones**. Compara cada par posible de datos (X_i, Y_i) con (X_j, Y_j) y los clasifica como:
 - *Pares Concordantes:* Ambas variables aumentan juntas.
 - *Pares Discordantes:* Una aumenta y la otra disminuye.
 - *Pares Empatados:* Mismo valor en X o en Y.

Al basarse en conteos de pares y probabilidades de concordancia, la Tau de Kendall maneja los empates de forma nativa y elegante. La variante **Tau-b** introduce un ajuste matemático específico en su denominador que penaliza explícitamente los empates, proporcionando una medida de asociación mucho más conservadora, exacta y estadísticamente robusta para bases de datos masivas con variables categóricas altamente concentradas en un solo valor.

* Entre más pares concordantes (que presenten el mismo comportamiento donde ambas variables aumentan), más cercano a 1 es el outcome.

* Entre más pares **discordantes** (que presenten el mismo comportamiento donde una variable aumenta y la otra disminuye), más cercano a -1 es el outcome.

* Pares iguales no aporta en el numerador, pero si influye en el denominador

Para ver exactamente cómo sucede este efecto de "castigo", necesitamos mirar la fórmula matemática de la **Tau-b de Kendall**.

La fórmula se ve así:

$$\tau_b = \frac{C - D}{\sqrt{(C + D + E_X) \cdot (C + D + E_Y)}}$$

Donde:

- C = Número de pares **Concordantes**
- D = Número de pares **Discordantes**
- E_X = Número de pares empatados **solo en X** (horas de uso)
- E_Y = Número de pares empatados **solo en Y** (satisfacción en estrellas)
- (Nota: Los empates dobles, donde dos usuarios tienen exactamente las mismas horas y las mismas estrellas, se descartan por completo de la fórmula).

5. Diagnóstico de Multicolinealidad

* **Multicolinealidad:** En el contexto de la estadística y los modelos de regresión, la multicolinealidad ocurre cuando **dos o más variables predictoras (las variables del modelo) están altamente correlacionadas entre sí**.

Modelo para predecir consumo de combustible con: X1 (Peso), X2 (Capacidad), X3 (Distancia). La regresión auxiliar de X1 contra X2 y X3 arroja un $R_1^2 = 0,94$.

a) *Calcula matemáticamente el Factor de Inflación de Varianza (VIF_1).*

Respuesta: Para calcular el Factor de Inflación de Varianza (VIF) de una variable, utilizamos el coeficiente de determinación (R^2) obtenido al regresar esa variable contra todas las demás variables predictoras del modelo.

La fórmula matemática es:

$$VIF_i = \frac{1}{1 - R_i^2}$$

El problema nos indica que la regresión auxiliar de la variable X_1 (Peso) contra X_2 (Capacidad) y X_3 (Distancia) dio como resultado un $R_1^2 = 0.94$. Sustituyendo en la fórmula:

$$VIF_1 = \frac{1}{1 - 0.94}$$

$$VIF_1 = \frac{1}{0.06}$$

$$VIF_1 = 16.66$$

Interpretación: Un VIF igual a 1 indica que no hay correlación. En la industria, la regla de oro establece que un VIF mayor a 5 indica multicolinealidad problemática, y un VIF mayor a 10 indica multicolinealidad severa. Un VIF_1 de 16.66 confirma que la variable X_1 está fuertemente correlacionada con las otras dos.

b) ¿Qué le está sucediendo matemáticamente a la matriz del modelo de regresión?

Respuesta: Para entender la gravedad matemática de esto, debemos mirar las "tripas" de la regresión lineal. Cuando calculas los coeficientes de una regresión mediante el método de Mínimos Cuadrados Ordinarios (OLS), la computadora resuelve esta ecuación matricial:

$$\hat{\beta} = (X^T X)^{-1} X^T y$$

El corazón de esta fórmula es el cálculo de la matriz inversa: $(X^T X)^{-1}$.

Como X_1 puede ser casi perfectamente predicha por X_2 y X_3 (eso significa ese 94%), los vectores columna dentro de tu matriz de datos X son casi paralelos. Matemáticamente, decimos que la matriz pierde independencia lineal o se vuelve "mal condicionada" (ill-conditioned).

Cuando las columnas no son independientes, el determinante de la matriz $(X^T X)$ se acerca peligrosamente a cero. Y como calcular una matriz inversa requiere dividir entre el determinante (que ahora es casi cero), los valores dentro de la matriz inversa explotan hacia el infinito.

El resultado directo de esta explosión matemática es la "Inflación de la Varianza" (de ahí el nombre del indicador VIF). Los errores estándar de los coeficientes de tu modelo se vuelven gigantescos, lo que hace que tu modelo sea inestable. Un pequeño cambio en los datos de entrada podría hacer que el coeficiente de X_1 pase de positivo a negativo drásticamente.

c) Como analista, ¿qué decisión técnica debes tomar con la variable y por qué?

Respuesta: La decisión técnica más directa y habitual es eliminar la variable X_1 (Peso) del modelo, o alternativamente, fusionarla con X_2 si tienen sentido físico juntas (por ejemplo, creando una nueva variable de "Carga Total").

¿Por qué? Porque ese $R^2 = 0.94$ nos dice que el 94% de la información o varianza que aporta el "Peso" ya está contenida y explicada por la "Capacidad" y la "Distancia". Retener X_1 en el modelo es redundante; no le añade poder predictivo nuevo al sistema, pero a cambio, destruye la estabilidad matemática de tus estimaciones (como vimos en el punto b). Al eliminar X_1 , la matriz $(X^T X)$ recupera su independencia lineal, el determinante se estabiliza, los errores estándar se reducen y los coeficientes de X_2 y X_3 vuelven a ser interpretables y confiables, sin perder precisión real en la predicción.

6. Bootstrapping

Dado el arreglo $S = [2, 3, 2, 5, 4, 3, 1, 120]$ de tiempos de resolución:

a) Explica por qué utilizar la fórmula clásica del Error Estándar ($SE = s/\sqrt{n}$) y el t-test será analíticamente desastroso para estos datos.

Respuesta: Será un desastre total debido a la presencia de un valor atípico extremo (outlier) en una muestra minúscula.

Analicemos tu arreglo de datos: $S = [2, 3, 2, 5, 4, 3, 1, 120]$. Tienes un tamaño de muestra de $n = 8$. Siete de esos tickets se resolvieron en 5 horas o menos, pero hay un ticket catastrófico que tardó 120 horas.

1. **El colapso del promedio:** El t-test y la fórmula clásica del Error Estándar utilizan la media aritmética ($\bar{x}$). La media de estos datos es de 17.5 horas. ¡Este número no representa la realidad del negocio! La inmensa mayoría de los tickets se resuelven rapidísimo, pero ese "120" jala el promedio hacia arriba, dando una falsa impresión operativa.
2. **La explosión de la varianza:** La desviación estándar muestral (s) mide qué tan alejados están los datos del promedio. El dato "120" está a más de 100 horas de distancia del promedio (17.5). En la fórmula de la varianza matemática, las distancias se elevan al cuadrado. Esto hará que la varianza y, en consecuencia, el Error Estándar (SE) exploten hacia un número gigantesco.
3. **El desastre analítico:** Si tu Error Estándar es gigantesco, cuando intentes calcular un Intervalo de Confianza clásico (que es $\text{Media} \pm \text{Margen de Error}$), el resultado podría decirte algo ridículo como: "Con un 95% de confianza, el tiempo de resolución está entre -20 horas y 55 horas". Un tiempo negativo es físicamente imposible, demostrando que la matemática paramétrica clásica se rompió por violar el supuesto de normalidad.

b) Describe el algoritmo paso a paso para calcular un Intervalo de Confianza (IC) al 95% para la mediana mediante Bootstrapping.

Respuesta: El Bootstrapping No Paramétrico (distribución sin conocer parámetros, aka sin conocer la distribución de los datos) es una técnica de fuerza bruta computacional. En lugar de usar fórmulas rígidas que asumen distribuciones perfectas, utiliza el poder de la computadora para simular miles de escenarios basándose únicamente en los datos reales que tienes.

Aquí está el algoritmo paso a paso:

1. Muestreo con Reemplazo (El paso mágico): Metes la mano en la bolsa, sacas una pelota, anotas su número en un papel... y devuelves la pelota a la bolsa. Mezclas bien y sacas otra. Haces esto 8 veces para crear una "nueva" muestra del mismo tamaño que la original.

- ¿Por qué hacer esto? Al devolver la pelota, permites que algunos números se repitan y que otros no salgan. Una muestra simulada podría ser [2, 2, 2, 5, 4, 1, 1, 3] (¡el 120 no salió!). Otra podría ser [120, 3, 3, 4, 5, 2, 1, 120] (¡el 120 salió dos veces!). Esto simula todas las posibles realidades operativas de tu negocio basándose en lo que ya ocurrió.

2. Calcular el Estadístico: A esa nueva muestra inventada de 8 números, le calculas la mediana y la anotas en una libreta.

3. Fuerza Bruta (El ciclo): Repites el Paso 1 y el Paso 2 miles de veces (por ejemplo, 10,000 veces). Al final, tu libreta tendrá 10,000 medianas diferentes.

4. Construir el Intervalo (Percentiles): Ordenas las 10,000 medianas de menor a mayor. Como quieres un Intervalo de Confianza del 95%, significa que quieres ignorar el 5% de los escenarios más extremos (los muy optimistas y los muy pesimistas). Así que eliminas el 2.5% de los valores más bajos de tu libreta, y el 2.5% de los valores más alto. Los dos números que quedan en los bordes forman tu intervalo final.

Ejemplo Python:

Python

```
import numpy as np

# 1. Definimos nuestra muestra original (el tiempo en horas)
S = np.array([2, 3, 2, 5, 4, 3, 1, 120])

# Configuramos el experimento de Bootstrapping
B = 10000 # Número de simulaciones (iteraciones)
medianas_simuladas = [] # Aquí guardaremos las 10,000 medianas

# 2 y 3. Iniciamos el ciclo de fuerza bruta
for i in range(B):
    # Generamos una nueva muestra CON REEMPLAZO (replace=True es vital)
    # size=len(S) asegura que saquemos exactamente 8 "pelotas" cada vez
    muestra_bootstrap = np.random.choice(S, size=len(S), replace=True)

    # Calculamos la mediana de esta nueva muestra simulada
    mediana_actual = np.median(muestra_bootstrap)

    # Guardamos el resultado en nuestra lista
    medianas_simuladas.append(mediana_actual)

# 4. Calculamos los percentiles para formar el Intervalo de Confianza al 95%
# Cortamos el 2.5% inferior y el 97.5% superior
limite_inferior = np.percentile(medianas_simuladas, 2.5)
limite_superior = np.percentile(medianas_simuladas, 97.5)

print(f"La Mediana original es: {np.median(S)} horas")
print(f"Intervalo de Confianza al 95% para la Mediana: [{limite_inferior}, {limite_superior}]")
```

c) Si modelaras los datos con una distribución, ¿cuál usarías y cuál es su parámetro de tendencia central?

Respuesta: Dado que estamos hablando de "Tiempos de Resolución" que no pueden ser negativos (están acotados en cero) y tienen una clara asimetría positiva severa (la gran mayoría de los valores son pequeños, pero existe una cola larga (*sesgo*) hacia la derecha por el 120), utilizaría la **Distribución Lognormal**.

- **Distribución sugerida:** Lognormal.
- **Parámetro de tendencia central:** El parámetro natural de tendencia central (el valor que mejor representa lo típico/normal) en la familia Lognormal suele expresarse como e^μ (exponencial de μ), que matemáticamente corresponde a la mediana teórica de la distribución, no a su media aritmética.

d) Describe el proceso de Bootstrapping Paramétrico (Monte Carlo). ¿Qué ventajas y desventajas tiene frente al no paramétrico?

* Monte Carlo: Se generan datos sintéticos (nuevos) y se utilizan para los cálculos

Respuesta: Mientras que en el paso "b" sacábamos papelitos de la bolsa de los datos originales, en el Bootstrapping Paramétrico (también conocido como simulaciones de Monte Carlo) cambiamos las reglas del juego.

El Proceso:

1. **Ajuste:** En lugar de Re muestrear los datos puros, agarras tu muestra S y calculas qué tan bien encaja en una ecuación matemática perfecta (como la distribución Lognormal que elegimos arriba).
2. **Simulación:** Una vez que el algoritmo encuentra los parámetros teóricos de esa curva Lognormal (por ejemplo, la forma y la escala), **descartas los datos originales**. Ahora, le pides a la computadora que

genere miles de muestras nuevas de 8 datos, pero extrayéndolas artificialmente de esa ecuación matemática.

3. **Cálculo:** Calculas la mediana de cada muestra artificial y sacas los percentiles, igual que en el método anterior.

Ventajas:

- **Suavidad y extrapolación:** A diferencia del método no paramétrico que está "atrapado" repitiendo los mismos 8 números (1, 2, 3, 4, 5, 120), el método paramétrico genera números completamente nuevos basándose en la probabilidad (podría simular tiempos de 2.5 horas, o 4.8 horas).
- **Eficiencia:** Si la distribución que elegiste es la correcta, este método requiere menos datos para ser preciso porque se apoya en la teoría matemática.

Desventajas:

- **Riesgo de sesgo por mala especificación:** Esta es su debilidad fatal. Si tú asumes que los datos siguen una distribución Normal, y en realidad eran Lognormales, todo el castillo de naipes se derrumba. Tus miles de simulaciones generarán datos basados en una mentira matemática, y tus conclusiones de negocio estarán equivocadas. El no paramétrico, al basarse en los datos crudos, no requiere que adivines la distribución subyacente.

7. Modelado y Cálculo de Probabilidades

La gerencia de operaciones de una empresa de software B2B te pide analizar el "Tiempo de Resolución de Tickets de Soporte Técnico Nivel 3"(en horas). Te entregan un set de 3 gráficas (Histograma, Q-Q Plot contra una Normal, y un eCDF - Figura 1):




Figura 1: Tiempo de Resolución de Tickets de Soporte Técnico Nivel 3(en horas)

a) *Diagnóstico Distribucional:* Explica por qué modelar estos tiempos con una Normal sería un error. ¿Qué familia de distribuciones propondrías y qué característica visual del histograma sustenta tu elección?

Respuesta: Utilizar la distribución Normal clásica para modelar tiempos de resolución de soporte técnico es un error estadístico fundamental debido a dos violaciones de sus propiedades teóricas:

1. **Límite Físico (Variables no negativas):** La distribución Normal está definida desde el infinito negativo hasta el infinito positivo $(-\infty, +\infty)$. El tiempo es una magnitud física que no puede tomar valores negativos; es imposible que un técnico resuelva un ticket en -5 horas. Al forzar una curva Normal sobre estos datos, el modelo matemático inevitablemente asignará un porcentaje de probabilidad a que ocurran tiempos negativos (la campana se estira infinitamente hacia la izquierda; siempre habrá una minúscula fracción de área/probabilidad en los números negativos), lo cual es un absurdo lógico.
 2. **Violación de la Simetría:** La Normal asume una dispersión simétrica alrededor de su media. En soporte técnico de nivel 3, la realidad operativa es inherentemente asimétrica: la gran mayoría de los tickets se resuelven de forma relativamente rápida, pero unos pocos incidentes complejos pueden tardar días o semanas, arrastrando el promedio hacia arriba.
- **Familia de distribuciones propuesta:** Lo correcto es proponer distribuciones especializadas en modelar tiempos de espera, duración o fiabilidad, como la **Lognormal**, la **Exponencial**, la **Gamma** o la **Weibull**.
 - **Característica visual que lo sustenta:** El histograma muestra una **asimetría positiva fuerte (o sesgo a la derecha)**. Visualmente, esto se identifica porque la mayor "montaña" de datos (la moda) está concentrada

a la izquierda, cerca del cero, seguida de una "cola" muy larga, delgada y plana que se extiende hacia los valores altos en el lado derecho del eje X.

b) *Cálculo de Probabilidad (SLA): El SLA exige que el 80% de los tickets se resuelvan ≤ 24 horas. Explica cómo determinarías si se cumple la meta usando el eCDF.*

Respuesta: La gráfica **eCDF** (Función de Distribución Acumulada Empírica) es la herramienta perfecta para esto porque **no cuenta frecuencias aisladas** (como el histograma), sino que **suma directamente las probabilidades**. En el eje X tienes el "Tiempo" y en el eje Y la "Probabilidad Acumulada" de 0 a 1 (0% a 100%).

Para determinar si se cumple el SLA (Service Level Agreement), el procedimiento es puramente geométrico sobre la gráfica:

1. Te ubicas en el **eje X horizontal** y localizas la marca exacta de **24 horas**.
2. Desde ahí, trazas una línea recta vertical hacia arriba hasta **interceptar la curva** de la eCDF.
3. Desde ese punto de intersección en la curva, trazas una línea recta horizontal hacia la izquierda para leer el valor correspondiente en el **eje Y vertical**.
4. Ese valor que lees es matemáticamente la probabilidad empírica de resolver un ticket en ese tiempo o menos: $P(X \leq 24)$.
5. **Decisión:** Si el valor leído en el eje Y es **0.80 o mayor** (por ejemplo, **0.85**), significa que el 85% de los tickets se cerraron en 24 horas o menos, por lo que **sí se cumple el SLA**. Si el cruce ocurre por debajo de **0.80**, la meta no se está alcanzando.

* En este caso, la línea cruza alrededor de 0.66 aka 66% por lo que no se cumple que el 80% de los tickets se resuelven en 24 horas o menos


c) *Análisis de Riesgo: Estima la probabilidad empírica de que un ticket tarde más de 40 horas en resolverse usando la gráfica eCDF.*

Respuesta: Aquí reside una pequeña "trampa" matemática. Por definición, la eCDF siempre te entrega la probabilidad acumulada *hacia atrás*, es decir, la probabilidad de que el evento ocurra en un tiempo "menor o igual a" ($P(X \leq x)$).

Sin embargo, el análisis de riesgo te pide calcular una probabilidad *hacia adelante*, es decir, un tiempo "mayor a" ($P(X > 40)$).

Para resolverlo usando la misma gráfica, debes aplicar la **Regla del Complemento**. Dado que la suma total de todas las probabilidades posibles en tu sistema siempre es exactamente 1 (el 100%), la fórmula es:

$$P(X > 40) = 1 - P(X \leq 40)$$



El proceso paso a paso sería:

1. Buscas las **40 horas** en el eje X, subes a la curva y lees el valor en el eje Y.
2. Supongamos (aproximando visualmente una eCDF típica de este tipo) que en 40 horas el eje Y marca \$0.90\$. Esto significa que el 90% de los tickets se resolvieron en 40 horas o menos.
3. Aplicas el complemento matemático: $1 - 0.90 = 0.10$.
4. **Conclusión:** La probabilidad empírica de que un ticket se convierta en un riesgo y supere las 40 horas de resolución es del **10%**. Es decir, todo el espacio vertical que sobra desde la curva hasta llegar al "techo" del 1.0 es tu zona de riesgo.

* En este caso, la línea cruza alrededor de 0.88 aka 88%, entonces $1 - 0.88 = 0.22$, lo cual significa que hay aproximadamente un 22% de probabilidad de que un ticket tarde más de 40 horas en resolverse

Ruido: Variabilidad aleatoria

Anomalia: Valor raro pero posible

Error: Valor imposible

Local Outlier Factor (LOF)

- Basado en densidad; busca outliers locales
- Mide desviación de la densidad de un punto con respecto a sus vecinos

1. K distance

- Para punto "p" y un entero "k"
- K-distance (p) es la distancia $d(o, p)$ al k-ésimo vecino más cercano

2. Distancia de Alcance (Reachability)

- Evitar fluctuaciones estadísticas en áreas de alta densidad
- Reachability entre p y o

$$\text{reach-dist}_k(p, o) = \max \{ k - d(o), d(o, p) \}$$

- Si p cerca de o, distancia se "satura" usando K-distance de o
- Si p lejos de o, se usa distancia real

3. Densidad de Alcance Local (LDR)

- LDR de punto p es la inversa del promedio de reachability de sus vecinos

$$\text{LDR}_k(p) = \frac{|N_k(p)|}{\sum_{o \in N_k(p)} \text{reach-dist}_k(p, o)}$$

* Alta densidad → poco reachability; LDR grande
* Baja densidad → gran reachability; LDR pequeño


4. Índice Local Outlier Factor

- Promedio del ratio entre LDR de "p" y sus vecinos


$$\text{LOF}_k(p) = \frac{\sum_{o \in N_k(p)} \frac{\text{LDR}_k(o)}{\text{LDR}_k(p)}}{|N_k(p)|}$$

LOF ≈ 1 : densidad de p similar a vecinos; normal
LOF < 1 : densidad de p mayor (normal)
LOF > 1 : densidad de p menor (outlier)

Probability Density Function (PDF)




Cumulative Density Function (CDF)



NOTAS:


- * Aplicar transformaciones para normalizar datos y usar herramientas lineales
- * Cuando hay correlación puedes esperar algo de "y" según "x"
- * Alta correlación puede indicar datos redundantes



Corr BMT-Peso ≈ 1

Corr BMT-Alto ≈ 1

* Continuo $\rightarrow \mathbb{N}[0, \infty)$ * Discreto $\rightarrow \mathbb{R}(-\infty, \infty)$



Fundamentos Estadísticos

Estadística: marco matemático para cuantificar la incertidumbre al pasar de los datos observados (muestra) a conclusiones generalizadas del sistema (población).
empírico teórico

Población (N): Conjunto universal de todos los elementos. Parámetros constantes pero desconocidos (μ, σ^2)

Muestra (n): subconjunto representativo de la población. Se describe mediante estadísticos, que son variables aleatorias con su propia distribución de probabilidad.

$\bar{x}$ media muestral

s^2 : varianza muestral

Probabilidad y Distribuciones

Discretas: modelan variables aleatorias con espacio muestral numerable.

1. **Binomial:** modela éxitos "k" en "n" ensayos de Bernoulli, probabilidad de éxito "p".

PMF: $P(X=k) = \binom{n}{k} p^k (1-p)^{n-k}$
f de masa de probabilidad

Momentos Estadísticos:

$$E[X] = np$$

$$\text{Var}[X] = np(1-p)$$

2. **Poisson:** Modela conteos de eventos en un intervalo continuo de tiempo o espacio con tasa λ

PMF: $P(X=k) = \frac{\lambda^k e^{-\lambda}}{k!}$

Momentos Estadísticos:

$$E[X] = \lambda$$

$$\text{Var}[X] = \lambda$$

Continuas: Modelan variables en un rango continuo mediante una función de densidad de probabilidad (PDF)

1. **Normal (Gaussiana)**

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} e^{\left\{-\frac{1}{2}\frac{(x-\mu)^2}{\sigma^2}\right\}}$$

Momentos Estadísticos:

$$E[X] = \mu$$

$$\text{Var}[X] = \sigma^2 ; \mu \in \mathbb{R} \quad \sigma > 0$$

2. **Exponencial:** Modela el tiempo de espera entre evento en un proceso de Poisson.

$$f(x) = \lambda e^{-\lambda x} ; \lambda > 0 \text{ (tasa)}$$

Momentos Estadísticos:

$$E[X] = 1/\lambda$$

$$\text{Var}[X] = 1/\lambda^2$$

3. **Gamma:** Modela tiempo de espera hasta que ocurran d eventos

$$f(x) = \frac{\lambda^d x^{d-1} e^{-\lambda x}}{\Gamma(d)}$$

Momentos Estadísticos:

$$E[X] = d/\lambda$$

$$\text{Var}[X] = d/\lambda^2$$

$$; d > 0 \text{ (forma)} \quad \lambda > 0 \text{ (tasa)}$$

4. **Log-Normal:** modela variables cuyo logaritmo natural se distribuye normalmente

$$f(x) = \frac{1}{x \sigma \sqrt{2\pi}} \exp\left(-\frac{[\ln(x) - \mu]^2}{2\sigma^2}\right)$$

Momentos Estadísticos:

$$E[X] = \exp\left(\mu + \frac{\sigma^2}{2}\right)$$

5. **Uniforme:** describe un fenómeno donde hay un resultado equiprobable en un intervalo $- \infty < a < b < \infty$

$$f(x) = \begin{cases} \frac{1}{b-a} & \text{para } x \in [a, b] \\ 0 & \text{para todo lo demás} \end{cases}$$

Momentos Estadísticos:

$$E[X] = \frac{1}{2} (a+b)$$

$$\text{Var}[X] = \frac{1}{12} (b-a)^2$$

Exploratory Data Analysis (EDA)

H_0 : Hipótesis nula ~ lo que en teoría debería pasar

H_a : Hipótesis alterna ~ lo que pasa cuando H_0 se rechaza

p -value: determina cual hipótesis se rechaza; ninguna se "acepta" como tal

$p < 0.05$: rechaza H_0

$p \geq 0.05$: rechaza H_a

Estadística Descriptiva

★ Media = Mediana

★ Sesgo = 0

★ Kurtosis = N/A

Comparación de Tendencia Central

5. Resumen de Pruebas y Decisiones: Paramétrico vs No Paramétrico

Esta tabla sintetiza qué prueba utilizar basándose en los resultados de validación (normalidad y homocedasticidad).

Categoría	Prueba Estadística	¿Cuándo usarla?	Hipótesis Nula (H_0)	Interpretación si $p < 0.05$
Validación	Shapiro-Wilk	Antes de comparar grupos	Los datos son Normales	No es Normal → Usar pruebas No Paramétricas (Mann-Whitney)
Validación	Levene	Antes de comparar grupos	Las varianzas son Iguales <i>homocedasticidad</i>	Varianzas Distintas → Usar Welch en lugar de T-Student clásica <i>heterocedasticidad</i>
Comparación (2 Grupos)	T-Student / Welch	Datos Normales (Paramétrica)	Medias Iguales	Existe diferencia significativa entre las medias
Comparación (2 Grupos)	U de Mann-Whitney	Datos No Normales (No Paramétrica)	Distribuciones Iguales	Existe diferencia significativa entre las distribuciones
Comparación (>2 Grupos)	ANOVA	Datos Normales (Paramétrica)	Todas las medias iguales	Al menos un grupo es diferente a los demás
Asociación	Chi-Cuadrada (χ^2)	Variables Categóricas	Variables Independientes	Existe relación entre las variables <i>dependientes</i>
Distancia	Kolmogorov-Smirnov	Comparar formas de distribución	Misma distribución	Las distribuciones son diferentes

Regla de Oro:

- Primero ejecuta **Shapiro-Wilk**. *~ verificar normalidad*
 - Si $p > 0.05$ (es Normal) → Usa **T-Student / ANOVA**.
 - Si $p < 0.05$ (No es Normal) → Usa **Mann-Whitney / Kruskal-Wallis**.
- Si es Normal, ejecuta **Levene**.
 - Si $p < 0.05$ (Varianzas distintas) → Asegúrate de usar **Welch's T**.

Correlación: medida estadística que indica relación entre 2 variables numéricas

★ $R \in [-1, 1]$

★ $R > 0$ (positiva): ambas vars. se mueven en misma dirección

★ $R < 0$ (negativa): variables se mueven en direcciones opuestas

Pearson: mide dependencia lineal y utiliza valores absolutos

$$r = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum (x_i - \bar{x})^2} \sqrt{\sum (y_i - \bar{y})^2}}$$

★ Matemáticamente inmutable.

★ Anomalías pueden arrastrar la r de 0 a 0.9

★ Relaciones Monótonas NO lineales; si X_1 crece

exponencialmente cuando X_2 crece, Pearson subestimará la relación

★ Monótono: X_1 & X_2 aumentan sin importar la tasa o curva

Spearman (ρ || r_s): mide relación monótona (no necesariamente lineal); mejor para datos ordinales o con valores atípicos; trabaja con rangos en lugar de valores

$$r_s = 1 - \frac{6 \sum d_i^2}{n(n^2 - 1)}$$

★ n : tamaño de la muestra

★ d_i : diferencia entre el rango de X_1 y X_2 para la observación i

Kendall: se basa en concordancia y discordancia al comparar por conjuntos o pares de datos