

Análisis de Readmisiones Hospitalarias, Recurrencia y Estancia en Pacientes Diabéticos

Proyecto Final de Data Analytics

Universidad Iberoamericana
Primavera 2026

Resumen

Este proyecto analiza datos hospitalarios de pacientes con diabetes para estudiar tres fenómenos: readmisión en menos de 30 días, recurrencia hospitalaria y duración de la estancia. El análisis combina limpieza de datos, análisis exploratorio, pruebas estadísticas y modelos interpretables. La idea central es que estos tres fenómenos están relacionados, pero no son iguales. Por eso se usaron modelos distintos: regresión logística para readmisión, modelos de conteo para recurrencia y un modelo Gamma para la estancia. Los resultados sugieren que los pacientes con mayor uso previo del hospital y mayor complejidad clínica concentran buena parte del riesgo operativo.

1. Problema de negocio

El hospital quiere entender mejor por qué algunos pacientes con diabetes regresan pronto, por qué otros acumulan varias admisiones y por qué ciertas estancias duran más. Esto importa porque las readmisiones afectan la calidad de atención y también presionan camas, personal y costos.

El proyecto responde tres preguntas: (1) ¿qué factores se relacionan con la readmisión en menos de 30 días?, (2) ¿qué factores se relacionan con más admisiones hospitalarias previas? y (3) ¿qué factores se relacionan con estancias más largas?

2. Datos y preparación

Se trabajó con el conjunto *Diabetes 130-Hospitals*. La base original contiene 101,766 admisiones y 50 variables. Para la versión final se siguió la limpieza más estricta: se conservaron pacientes únicos, se excluyeron egresos terminales y se eliminaron variables con demasiados faltantes. La muestra final quedó en 69,970 observaciones.

Las decisiones de limpieza más relevantes fueron: convertir los valores ? en faltantes reales, eliminar `weight` por exceso de faltantes, conservar algunas ausencias como categoría *Desconocido* cuando aportaban información, usar solo un registro por paciente para preservar la independencia de las observaciones y crear la variable binaria `readmit_30d` (1 si el paciente regresó en menos de 30 días). La calidad de la limpieza condiciona directamente la validez de los modelos posteriores, por lo que cada decisión se documentó con su criterio de inclusión o exclusión.

3. Análisis exploratorio

La primera figura resume las tres variables principales del proyecto: estancia, recurrencia y readmisión.




Figura 1: Distribuciones de las variables respuesta: estancia, admisiones previas y readmisión a 30 días.

La estancia está sesgada a la derecha: la mayoría de los pacientes permanece pocos días, pero algunos se quedan mucho más. La recurrencia tiene muchos ceros y una cola larga. La readmisión a 30 días es un evento poco frecuente.

También se revisó la tasa de readmisión por edad.




Figura 2: Tasa de readmisión a 30 días por grupo de edad.

La tasa no es estrictamente lineal, pero los grupos de mayor edad presentan tasas más altas y estables, lo que es consistente con la mayor comorbilidad y uso del sistema de salud en esos rangos.

Para revisar relaciones entre variables numéricas se usó correlación de Spearman. Se eligió Spearman porque varias variables son asimétricas y no siguen una relación lineal simple.




Figura 3: Correlación de Spearman entre variables clínicas y de uso hospitalario.

La matriz muestra que las variables de uso previo del hospital se mueven juntas: los pacientes que ya han usado más urgencias, hospitalización o servicios ambulatorios tienden a formar un grupo de mayor carga operativa.

4. Inferencia estadística

Para confirmar formalmente los patrones observados se aplicaron cuatro pruebas: Kolmogorov-Smirnov (forma de la estancia), Mann-Whitney (estancia entre readmitidos y no readmitidos), Chi-cuadrada (asociación entre diagnóstico y readmisión) y Kruskal-Wallis (estancia entre grupos de edad).

Los resultados confirman que existen diferencias reales entre los grupos. Aun así, con un tamaño de muestra tan grande casi cualquier diferencia resulta estadísticamente significativa, por lo que el valor del p-valor por sí solo no basta. Por eso se acompañaron las pruebas con tamaños de efecto, que cuantifican la magnitud práctica de cada diferencia (Tabla 1).

Tabla 1: Pruebas de inferencia y tamaños de efecto correspondientes

Prueba	Comparación	p-valor	Efecto	Magnitud
Mann-Whitney	estancia $\sim$ readmisión	$1,7 \times 10^{-56}$	Cliff's $\delta = -0,12$	pequeño
Chi ²	diagnóstico $\times$ readm.	$1,4 \times 10^{-12}$	V Cramér = 0,033	trivial
Kruskal-Wallis	estancia $\sim$ edad	~ 0	$\varepsilon^2 = 0,020$	pequeño

La interpretación es coherente: aunque los tres p-valores son cercanos a cero, las magnitudes de efecto son pequeñas. Es decir, las diferencias son reales pero modestas. Una diferencia de un día en la mediana de estancia es estadísticamente menor pero relevante a escala hospitalaria.

5. Modelos estadísticos

Diseño común

Las categóricas se codificaron como *dummies* (eliminando la primera categoría para evitar colinealidad). El ajuste se realizó con `statsmodels`. La logística se entrenó con división estratificada 75 / 25 con semilla fija; los modelos de conteo y el Gamma se ajustaron sobre todo el conjunto porque su evaluación es global (AIC, devianza explicada) y no de predicción individual.

5.1. Readmisión a 30 días

Para readmisión se usó regresión logística, porque la variable objetivo es binaria: el paciente se readmite en menos de 30 días o no.

El desempeño en el conjunto de prueba: AUC ROC = 0,608, PR-AUC = 0,137 frente a una línea base aleatoria de 0.090 (prevalencia 8.97 %), y pseudo R^2 de McFadden = 0,023.

Con una prevalencia tan baja, la curva ROC tiende a sobreestimar el desempeño percibido; por eso se reporta también la curva precisión-recall, más informativa cuando la clase positiva es rara (Figura 4). El AUC obtenido es modesto pero coherente con el rango típico de la literatura cuando se utilizan únicamente variables administrativas y clínicas estructuradas, sin notas médicas ni biomarcadores.




Figura 4: Diagnóstico del modelo logístico: curva ROC, curva precisión-recall y distribución de probabilidades predichas por clase real.

El modelo no predice de forma exacta, pero sí permite identificar qué factores acompañan al riesgo de readmisión.




Figura 5: Efectos principales de la regresión logística expresados como razones de probabilidades (OR), con intervalos de confianza al 95 %. Cuando la prevalencia es baja como aquí ($\sim 9\%$), la razón de probabilidades aproxima al riesgo relativo.

Los efectos más relevantes (Tabla 2) fueron:

Tabla 2: Factores asociados con la readmisión a 30 días (razones de probabilidades, todos con $p < 0,01$)

Variable	Razón de probabilidades	IC 95 %
Admisiones previas (cada una)	1.40	[1.36, 1.46]
Uso de medicamento para diabetes	1.21	[1.11, 1.32]
Visitas previas a urgencias	1.07	[1.03, 1.12]
Días de estancia (cada uno)	1.04	[1.03, 1.06]
Número de diagnósticos (cada uno)	1.04	[1.02, 1.06]

El predictor más importante es el historial de admisiones previas: cada ingreso adicional incrementa la razón de probabilidades de readmisión en un factor cercano a 1.40, equivalente a aproximadamente 40 % más oportunidad de reingreso que un paciente comparable sin ese antecedente. En conjunto, los pacientes con mayor historia de uso hospitalario presentan un mayor riesgo de readmisión temprana.

5.2. Recurrencia hospitalaria

La recurrencia se modeló como conteo. Primero se probó Poisson, pero los datos mostraban sobredispersión: la varianza era mayor que la media ($\text{Var}/\text{Media} \approx 2.05$). Por eso se comparó contra una Binomial Negativa, cuyo parámetro de dispersión α se estimó por máxima verosimilitud ($\alpha_{\text{MLE}} = 4,28$). Los modelos se compararon mediante el AIC (*criterio de información de Akaike*), una medida que combina el ajuste del modelo con una penalización por su complejidad: a menor AIC, mejor balance entre ajuste y parsimonia.

Tabla 3: Comparación de modelos para recurrencia hospitalaria

Modelo	AIC	Dispersión Pearson	Pseudo R^2
Poisson	73,034.86	1.93	0.129
Binomial Negativa (MLE)	64,346.37	1.13	0.065

La Binomial Negativa obtuvo un AIC sustancialmente menor ($\Delta AIC = 8,688$ a favor de la Binomial Negativa), y su dispersión Pearson se reduce a 1.13 (cercana al valor ideal de 1), lo que confirma que la sobredispersión se modela adecuadamente (Figura 6). Un subconjunto de pacientes concentra una fracción desproporcionada del uso hospitalario.




Figura 6: Distribución observada de admisiones previas (escala logarítmica) y comparación de AIC entre los modelos Poisson y Binomial Negativa.

Los efectos más fuertes (leídos como *incidence rate ratios*, IRR) fueron las visitas previas a urgencias (IRR = 1,77), el uso de medicamento para diabetes (IRR = 1,24) y las visitas ambulatorias previas (IRR = 1,13). Una visita adicional a urgencias multiplica el conteo esperado de admisiones por 1.77; este resultado ofrece un criterio operativo claro para identificar estos pacientes antes del alta.

5.3. Duración de la estancia

Para la duración de estancia se usó un modelo Gamma con enlace logarítmico. La razón es sencilla: los días de estancia son positivos y tienen sesgo a la derecha.




Figura 7: Diagnóstico del modelo Gamma para duración de estancia.

El modelo Gamma alcanzó un pseudo R^2 basado en devianza de 0.28, un valor satisfactorio para datos clínicos administrativos. Tomando como referencia la categoría diagnóstica circulatoria (eliminada como

base por la codificación con *drop_first*), las estancias en categorías como “Otros” (factor 1.34), Neoplasmas (1.29) y Diabetes (1.24) tienden a ser más prolongadas. Cada diagnóstico adicional incrementa la estancia esperada en aproximadamente 3 %, y cada admisión previa en alrededor de 3 %. En conjunto, la complejidad clínica del paciente es el factor principal que determina la duración esperada de la hospitalización.

6. Recomendaciones

Los resultados se traducen en tres recomendaciones operativas: (1) crear un programa de seguimiento al alta para pacientes con mayor uso previo del hospital; (2) emplear las visitas previas a urgencias y los ingresos previos como señales tempranas de recurrencia; y (3) considerar el diagnóstico y la complejidad clínica al planear camas y recursos. La recomendación principal es priorizar a los pacientes con mayor complejidad clínica y mayor uso previo del sistema: dado que el riesgo no es homogéneo, una asignación diferenciada de recursos resulta más eficiente.

7. Limitaciones

El análisis describe asociaciones, no relaciones causales. El dataset es administrativo, contiene faltantes relevantes y corresponde a hospitales de EE. UU. entre 1999 y 2008, por lo que las conclusiones deben interpretarse como guía contextual y no como regla generalizable. Adicionalmente, conservar un solo registro por paciente mejora la independencia de las observaciones pero descarta la trayectoria a lo largo del tiempo: el análisis describe el riesgo en una única visita y no captura cómo evoluciona con sucesivas admisiones. Una extensión natural serían los modelos longitudinales o de efectos mixtos, que aprovechan todas las admisiones del mismo paciente reconociendo que sus observaciones están correlacionadas.

8. Conclusión

Readmisión, recurrencia y duración de la estancia comparten señales de complejidad clínica y uso previo del sistema, pero no son el mismo fenómeno; por ello se ajustaron tres modelos distintos. La conclusión operativa central: los pacientes con mayor historia de uso hospitalario y mayor complejidad clínica concentran buena parte del riesgo, y su identificación temprana puede reducir readmisiones, optimizar la planeación de camas y mejorar el seguimiento posterior al alta.

Referencias

- [1] Strack, B., DeShazo, J. P., Gennings, C., Olmo, J. L., Ventura, S., Cios, K. J., y Clore, J. N. (2014). *Impact of HbA1c measurement on hospital readmission rates*. BioMed Research International, 2014, 781670.
- [2] Cameron, A. C. y Trivedi, P. K. (2013). *Regression Analysis of Count Data*, 2.^a ed. Cambridge University Press.
- [3] McCullagh, P. y Nelder, J. A. (1989). *Generalized Linear Models*, 2.^a ed. Chapman & Hall/CRC.
- [4] AHRQ. *Clinical Classifications Software (CCS) for ICD-9-CM*. `hcup-us.ahrq.gov`.
- [5] Akaike, H. (1974). *A new look at the statistical model identification*. IEEE TAC, 19(6), 716–723.
- [6] Seabold, S. y Perktold, J. (2010). *Statsmodels*. Proc. 9th Python in Science Conference.