

Análisis de Readmisiones Hospitalarias, Recurrencia y Estancia en Pacientes Diabéticos

Proyecto Final de Data Analytics

Universidad Iberoamericana
Primavera 2026

Resumen

Este proyecto analiza datos hospitalarios de pacientes con diabetes para estudiar tres fenómenos: readmisión en menos de 30 días, recurrencia hospitalaria y duración de la estancia. El análisis combina limpieza de datos, análisis exploratorio, pruebas estadísticas y modelos interpretables. La idea central es que estos tres fenómenos están relacionados, pero no son iguales. Por eso se usaron modelos distintos: regresión logística para readmisión, modelos de conteo para recurrencia y un modelo Gamma para la estancia. Los resultados sugieren que los pacientes con mayor uso previo del hospital y mayor complejidad clínica concentran buena parte del riesgo operativo.

1. Problema de negocio

El hospital quiere entender mejor por qué algunos pacientes con diabetes regresan pronto, por qué otros acumulan varias admisiones y por qué ciertas estancias duran más. Esto importa porque las readmisiones afectan la calidad de atención y también presionan camas, personal y costos.

El proyecto responde tres preguntas:

1. ¿Qué factores se relacionan con la readmisión en menos de 30 días?
2. ¿Qué factores se relacionan con más admisiones hospitalarias previas?
3. ¿Qué factores se relacionan con estancias más largas?

2. Datos y preparación

Se trabajó con el conjunto *Diabetes 130-Hospitals*. La base original contiene 101,766 admisiones y 50 variables. Para la versión final se siguió la limpieza más estricta: se conservaron pacientes únicos, se excluyeron egresos terminales y se eliminaron variables con demasiados faltantes. La muestra final quedó en 69,970 observaciones.

Las decisiones de limpieza más importantes fueron:

- convertir valores ? en faltantes reales;
- eliminar `weight`, porque tenía demasiados faltantes;
- conservar algunas ausencias como categoría *desconocido*, cuando podían tener valor informativo;
- usar solo un registro por paciente para mejorar la independencia de observaciones;
- crear la variable `readmit_30d`, que vale 1 si el paciente regresó en menos de 30 días.

La calidad de la limpieza condiciona directamente la validez de los modelos posteriores, por lo que cada decisión se documentó con su criterio de inclusión o exclusión.

3. Análisis exploratorio

La primera figura resume las tres variables principales del proyecto: estancia, recurrencia y readmisión.




Figura 1: Distribuciones de las variables respuesta: estancia, admisiones previas y readmisión a 30 días.

La estancia está sesgada a la derecha: la mayoría de los pacientes permanece pocos días, pero algunos se quedan mucho más. La recurrencia tiene muchos ceros y una cola larga. La readmisión a 30 días es un evento poco frecuente.

También se revisó la tasa de readmisión por edad.




Figura 2: Tasa de readmisión a 30 días por grupo de edad.

La tasa no es estrictamente lineal, pero los grupos de mayor edad presentan tasas más altas y estables, lo que es consistente con la mayor comorbilidad y uso del sistema de salud en esos rangos.

Para revisar relaciones entre variables numéricas se usó correlación de Spearman. Se eligió Spearman porque varias variables son asimétricas y no siguen una relación lineal simple.




Figura 3: Correlación de Spearman entre variables clínicas y de uso hospitalario.

La matriz muestra que las variables de uso previo del hospital se mueven juntas: los pacientes que ya han usado más urgencias, hospitalización o servicios ambulatorios tienden a formar un grupo de mayor carga operativa.

4. Inferencia estadística

Después del análisis visual se aplicaron pruebas estadísticas para confirmar si los patrones observados eran razonables.

Se usaron:

- Kolmogorov-Smirnov para revisar la forma de la estancia;
- Mann-Whitney para comparar estancia entre pacientes readmitidos y no readmitidos;
- Chi-cuadrada para revisar asociación entre diagnóstico y readmisión;
- Kruskal-Wallis para comparar estancia entre grupos de edad.

Los resultados confirman que existen diferencias reales entre los grupos. Aun así, con un tamaño de muestra tan grande casi cualquier diferencia resulta estadísticamente significativa, por lo que el valor del p-valor por sí solo no basta. Por eso se evaluó también el tamaño de cada efecto: una diferencia de un día en la mediana de estancia, por ejemplo, es modesta en términos estadísticos pero relevante a escala hospitalaria.

5. Modelos estadísticos

5.1. Readmisión a 30 días

Para readmisión se usó regresión logística, porque la variable objetivo es binaria: el paciente se readmite en menos de 30 días o no.

El desempeño fue moderado:

- AUC en prueba: 0.608.
- Pseudo R^2 de McFadden: 0.023.

El modelo no predice de forma exacta, pero sí permite identificar qué factores acompañan al riesgo de readmisión.




Figura 4: Efectos principales de la regresión logística expresados como factores multiplicativos sobre la probabilidad de readmisión.

El predictor más importante fue el historial de admisiones previas: cada ingreso adicional aumenta la probabilidad de readmisión por un factor cercano a 1.40 (es decir, alrededor de 40 % más alta que la de un paciente comparable sin ese antecedente). Las visitas previas a urgencias y el uso de medicamento para diabetes también resultaron relevantes. En conjunto, los pacientes con mayor historia de uso hospitalario presentan un mayor riesgo de readmisión temprana.

5.2. Recurrencia hospitalaria

La recurrencia se modeló como conteo. Primero se probó Poisson, pero los datos mostraban sobredispersión: la varianza era mayor que la media. Por eso se comparó contra una Binomial Negativa. Los modelos se compararon mediante el AIC (*criterio de información de Akaike*), una medida que combina el ajuste del modelo con una penalización por su complejidad: a menor AIC, mejor balance entre ajuste y parsimonia.

Tabla 1: Comparación de modelos para recurrencia hospitalaria

Modelo	AIC	Dispersión Pearson	Pseudo R^2
Poisson	73,034.86	1.93	0.129
Binomial Negativa	64,529.27	1.06	0.065

La Binomial Negativa obtuvo un AIC sustancialmente menor, lo que confirma que la recurrencia presenta sobredispersión: un subconjunto de pacientes concentra una fracción desproporcionada del uso hospitalario. La variable con mayor capacidad explicativa fue el uso previo de urgencias, lo que ofrece un criterio operativo claro para identificar estos pacientes antes del alta.

5.3. Duración de la estancia

Para la duración de estancia se usó un modelo Gamma con enlace logarítmico. La razón es sencilla: los días de estancia son positivos y tienen sesgo a la derecha.




Figura 5: Diagnóstico del modelo Gamma para duración de estancia.

El modelo indica que un mayor número de procedimientos y diagnósticos, así como ciertas categorías diagnósticas, se asocian con estancias más prolongadas. En conjunto, la complejidad clínica del paciente es el factor principal que determina la duración esperada de la hospitalización.

6. Recomendaciones

Los resultados se pueden traducir en tres recomendaciones:

1. Crear un programa de seguimiento al alta para pacientes con mayor uso previo del hospital.
2. Usar visitas previas a urgencias e ingresos previos como señales tempranas de recurrencia.
3. Considerar diagnóstico y complejidad clínica para planear camas y recursos.

La recomendación principal es priorizar a los pacientes con mayor complejidad clínica y mayor uso previo del sistema. Dado que el riesgo no es homogéneo, una asignación diferenciada de recursos resulta más eficiente desde el punto de vista operativo.

7. Limitaciones

El análisis describe asociaciones, no relaciones causales. Adicionalmente, el dataset es de naturaleza administrativa, contiene faltantes relevantes y corresponde a hospitales de Estados Unidos entre 1999 y 2008. Las conclusiones específicas deben interpretarse como una guía contextual, no como una regla generalizable.

Trabajar con un único registro por paciente mejora la independencia de las observaciones, pero reduce el tamaño efectivo de la muestra y descarta información sobre la trayectoria de cada paciente a lo largo del tiempo. Esto implica que el análisis describe el riesgo en una única

visita, pero no captura cómo evoluciona ese riesgo con sucesivas admisiones. Una extensión natural sería utilizar modelos longitudinales o de efectos mixtos, que permiten incluir todas las admisiones de un mismo paciente reconociendo que esas observaciones están correlacionadas entre sí, en lugar de tratarlas como si fueran independientes.

8. Conclusión

La readmisión, la recurrencia y la duración de la estancia comparten señales comunes de complejidad clínica y uso previo del sistema, aunque no constituyen el mismo fenómeno. Por ello se utilizaron herramientas distintas: regresión logística para readmisión, modelos de conteo para recurrencia y un modelo Gamma para la estancia.

La conclusión central es que los pacientes con mayor historia de uso hospitalario y mayor complejidad clínica concentran buena parte del riesgo operativo. Su identificación temprana puede contribuir a reducir readmisiones, optimizar la planeación de camas y mejorar el seguimiento posterior al alta.